Ejercicio 2.2 - Modelos

Cinco topologias pequenas entrenadas y exportadas a ONNX para visualizacion en Netron.

Dataset usado	Topologias	Mejor test acc	Mejor compromiso
2195 imagenes	**5 modelos**	**cnn_tiny (67.27%)**	**cnn_skip_pool**

Resumen de entrenamiento

Los modelos se tomaron desde model.py. Las imagenes se pasan a escala de grises y se redimensionan en memoria a 96x96, que es el tamano esperado por las capas fully connected y CNN. Split reproducible con seed 42: 70% train, 20% validacion y 10% test; entrenamiento por 20 epocas, batch 32, Adam lr=1e-3.

Modelo	Tipo	Val acc	Test acc	Params	Tamano	MACs	FLOPs	ONNX
fc_tiny	Fully connected	61.50%	60.00%	1,180,292	4.5025 MB	1.18e+06	2.36e+06	fc_tiny.onnx
fc_small	Fully connected	60.59%	59.09%	2,376,260	9.0647 MB	2.38e+06	4.75e+06	fc_small.onnx
cnn_tiny	CNN	69.70%	67.27%	295,572	1.1275 MB	1.29e+06	2.58e+06	cnn_tiny.onnx
cnn_gap	CNN + GAP	51.94%	50.00%	1,572	0.0060 MB	1.67e+06	3.34e+06	cnn_gap.onnx
cnn_skip_pool	CNN + skip pooling	73.35%	66.82%	14,060	0.0536 MB	8.18e+05	1.64e+06	cnn_skip_pool.onnx

Calculo de metricas reportadas

```
accuracy = aciertos / total_muestras
tamano_parametros_MB = parametros * 4 bytes / 1024^2 (float32)
FLOPs ~= 2 * MACs
MACs se obtuvieron con thop.profile(model, input=(1,1,96,96))
ONNX se exporto con torch.onnx.export y se abrio en Netron para las capturas.
```

Lectura rapida

cnn_tiny alcanza el mayor accuracy de test, pero ocupa mas de 1 MB en parametros float32. cnn_skip_pool queda practicamente empatado en accuracy, usa solo 0.0536 MB y necesita menos operaciones, por lo que se conserva como candidato principal para ESP32-S3.

Visualizacion Netron - fc_tiny

Test acc	Tamano	MACs	Params
60.00%	**4.5025 MB**	**1.18 M**	**1,180,292**

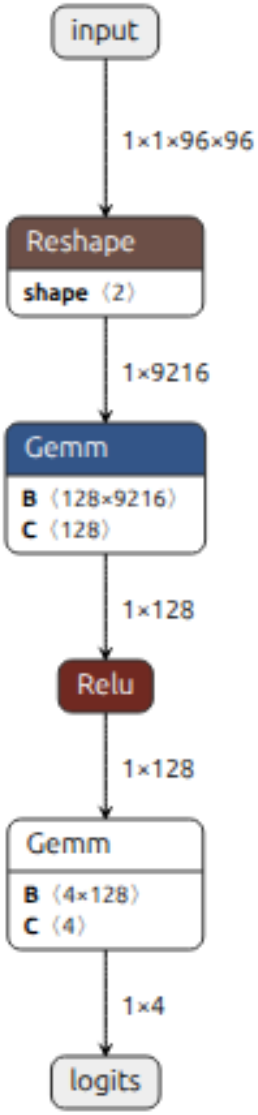

Visualizacion Netron - fc_small

Test acc	Tamano	MACs	Params
59.09%	**9.0647 MB**	**2.38 M**	**2,376,260**

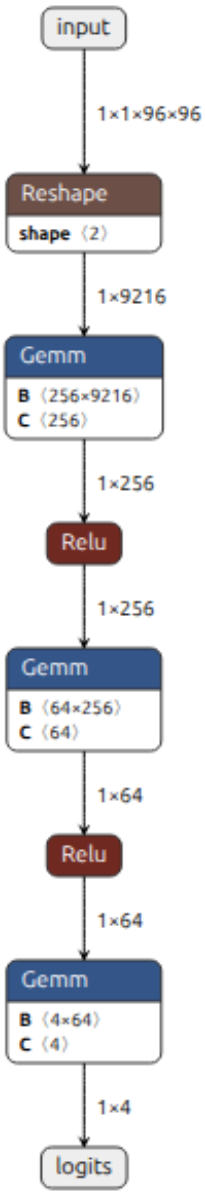

Visualizacion Netron - cnn_tiny

Test acc	Tamano	MACs	Params
67.27%	**1.1275 MB**	**1.29 M**	**295,572**

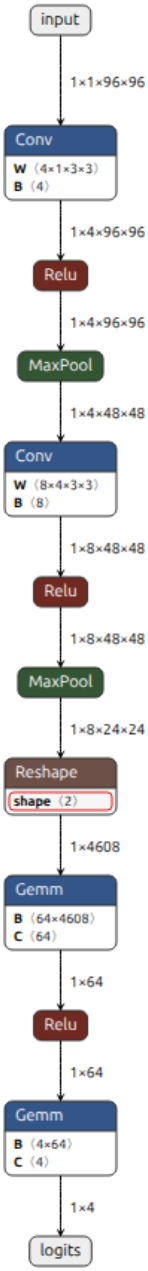

Visualizacion Netron - cnn_gap

Test acc	Tamano	MACs	Params
50.00%	**0.0060 MB**	**1.67 M**	**1,572**

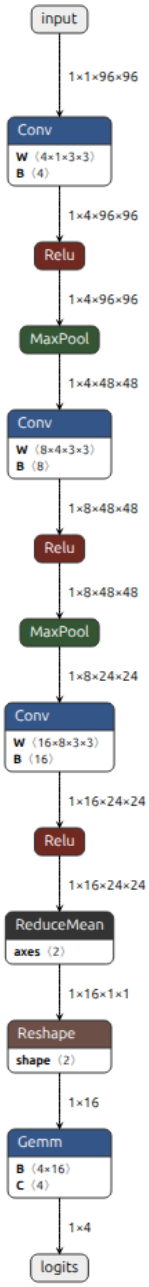

Visualizacion Netron - cnn_skip_pool

Test acc	Tamano	MACs	Params
66.82%	**0.0536 MB**	**0.82 M**	**14,060**

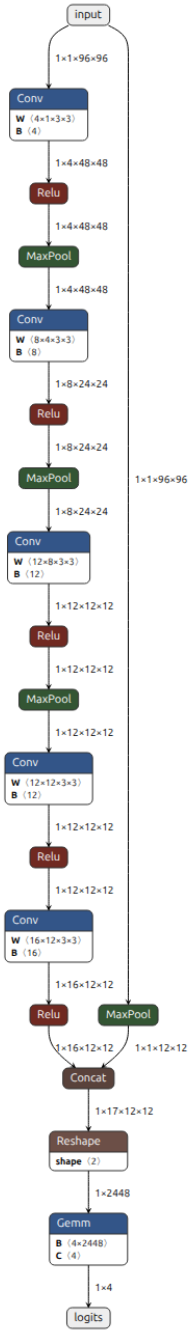

Ejercicio 2.3 - Estimacion en ESP32-S3

Latencia, FPS, potencia y movimiento de memoria estimados para cada red usando sus MACs y parametros reales.

Throughput efectivo	Potencia idle	Potencia activa	Limite SRAM
30 MMAC/s	**20 mW**	**240 mW**	**512 KB**

Supuestos de estimacion

Se modela un ESP32-S3 a 240 MHz ejecutando inferencia float32 sin cuantizacion. El throughput efectivo de 30 MMAC/s representa un caso base conservador; con cuantizacion int8 y kernels optimizados ESP-NN la latencia podria bajar de forma importante. Para potencia se usa carga promedio a 1 FPS.

Formulas usadas

```
latencia_s = MACs / 30,000,000
latencia_ms = latencia_s * 1000
FPS_estimado = 1 / latencia_s
potencia_mW = 20 + min(latencia_s / 1s, 1) * (240 - 20)
pesos_KB = parametros * 4 / 1024
bytes_movidos_capa = 4 * (elementos_input + elementos_output + parametros_capa)
activacion_pico_KB = max(tensores_intermedios) * 4 / 1024
```

Ejemplo aplicado: cnn_skip_pool

Calculo numerico

```
MACs = 818,496
latencia = 818,496 / 30,000,000 = 0.02728 s = 27.28 ms
FPS = 1 / 0.02728 = 36.7 FPS
potencia = 20 + 0.02728 * 220 = 26.0 mW
pesos = 14,060 * 4 / 1024 = 54.9 KB
```

Resultados por modelo

Modelo	Latencia	FPS	Potencia	Pesos	Act. pico	Trafico capas	SRAM
fc_tiny	39.34 ms	25.4	28.7 mW	4610.5 KB	36.0 KB	4648.5 KB	NO
fc_small	79.20 ms	12.6	37.4 mW	9282.3 KB	36.0 KB	9323.3 KB	NO
cnn_tiny	43.02 ms	23.2	29.5 mW	1154.6 KB	144.0 KB	2163.6 KB	NO
cnn_gap	55.61 ms	18.0	32.2 mW	6.1 KB	144.0 KB	1158.3 KB	OK
cnn_skip_pool	27.28 ms	36.7	26.0 mW	54.9 KB	36.0 KB	555.6 KB	OK

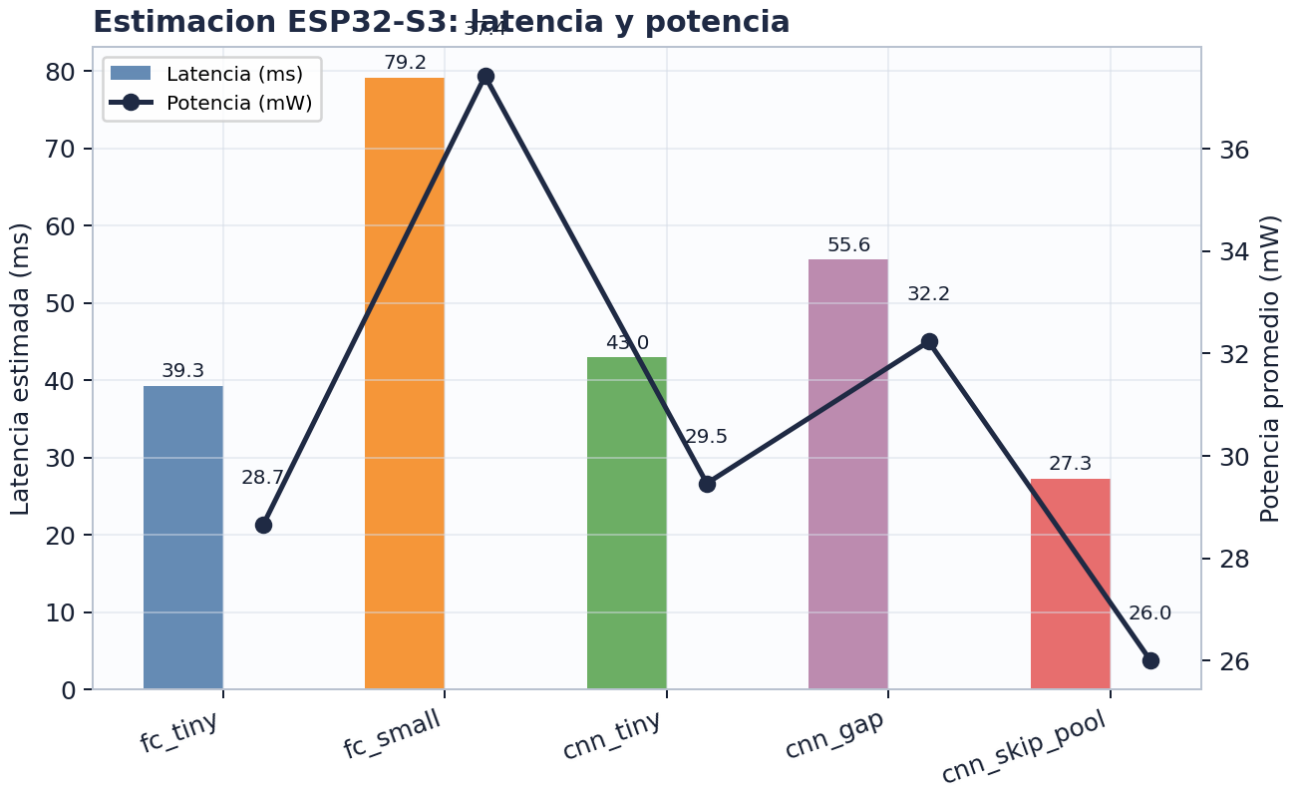

Conclusion 2.3

fc_tiny, fc_small y cnn_tiny quedan fuera del presupuesto de SRAM interna en float32. cnn_gap y cnn_skip_pool caben; cnn_skip_pool combina menor latencia, menor potencia estimada y accuracy competitivo.

Ejercicio 2.4 - Analisis

Comparacion grafica de accuracy, recursos estimados y Roofline por capa para elegir una red.

Red elegida	Test acc	Latencia	Tamano
cnn_skip_pool	**66.82%**	**27.3 ms**	**54.9 KB**

Como se construyeron los graficos

Graficos de comparacion

```
Cada punto = una topologia entrenada.
Eje Y = accuracy de test.
Accuracy vs tamano: eje X = parametros * 4 / 1024^2; linea roja = 0.5 MB SRAM.
Accuracy vs FPS: eje X = 1 / (MACs / 30e6).
Accuracy vs potencia: eje X = potencia_mW estimada con carga a 1 FPS.
```

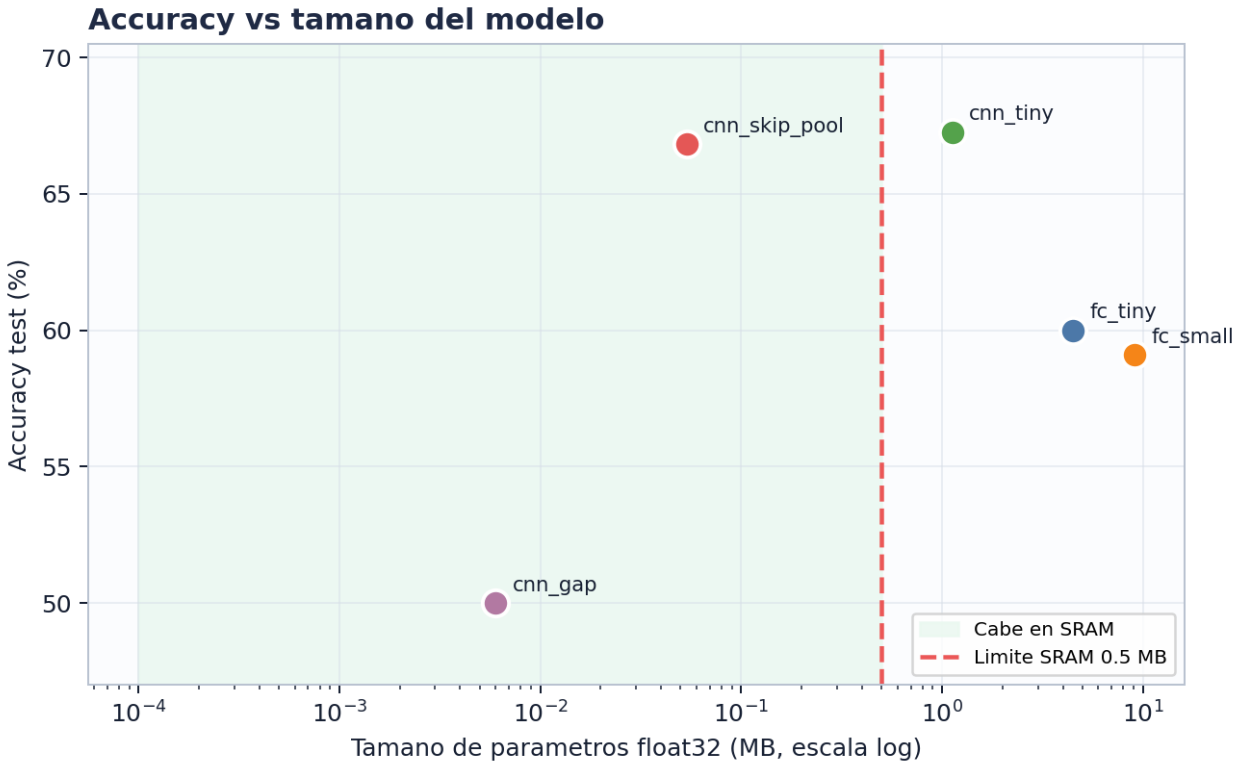

Trade-offs de desempeno

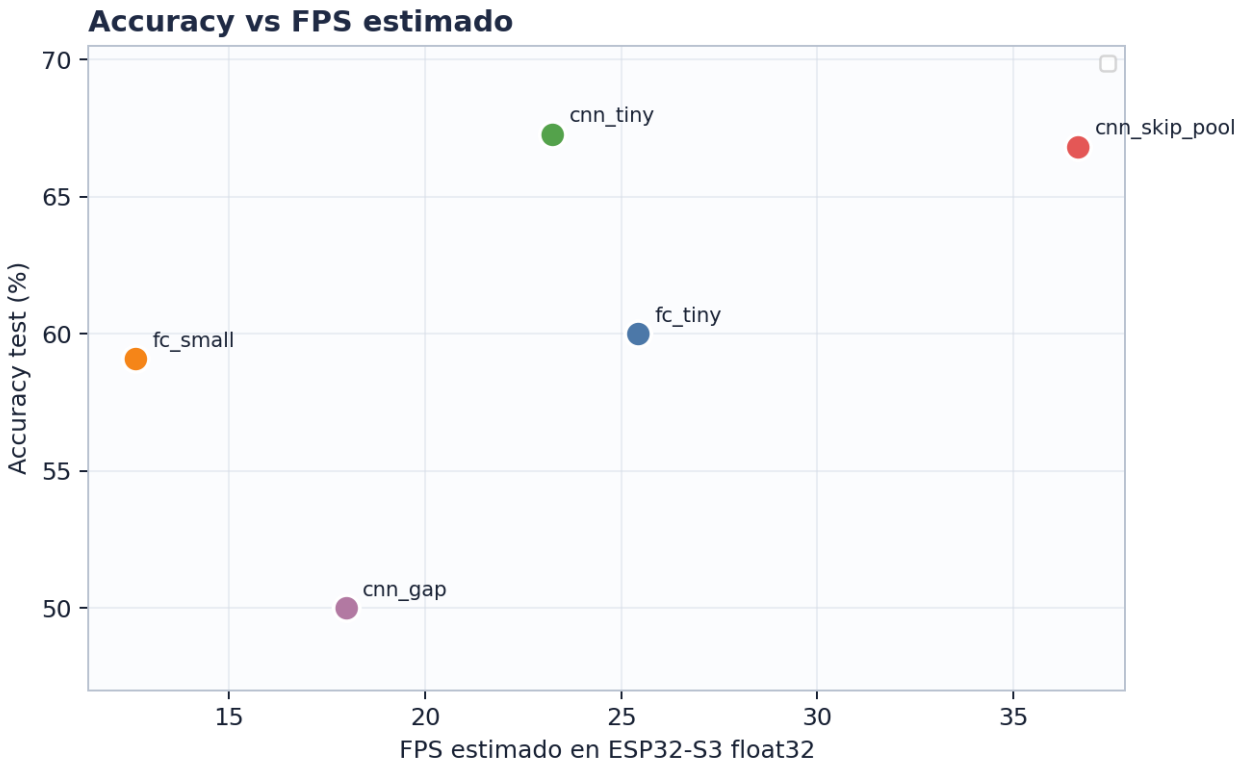

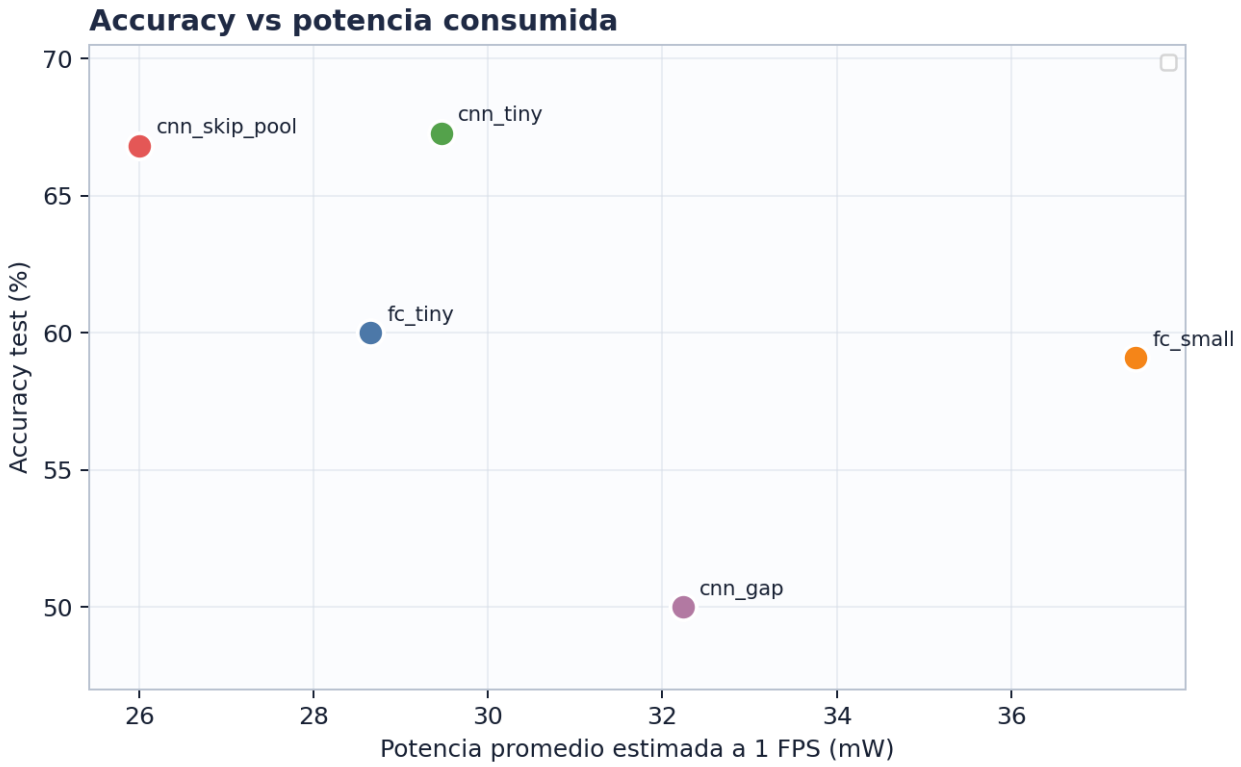

Roofline plot anotado

En este Roofline cada color identifica una red, cada forma identifica el tipo de capa y cada etiqueta corta identifica una capa especifica. Prefijos: FT=fc_tiny, FS=fc_small, CT=cnn_tiny, CG=cnn_gap y SP=cnn_skip_pool.

Calculo del Roofline

```
FLOPs_conv = elementos_output * (canales_in/groups * kernel_h * kernel_w) * 2
FLOPs_linear = elementos_output * in_features * 2
intensidad_operacional = FLOPs / bytes_movidos
tiempo_capa = max(FLOPs / pico_compute, bytes_movidos / bandwidth_memoria)
rendimiento_capa = FLOPs / tiempo_capa
pico_compute = 30 MMAC/s * 2 = 0.060 GFLOP/s; bandwidth = 0.12 GB/s
```

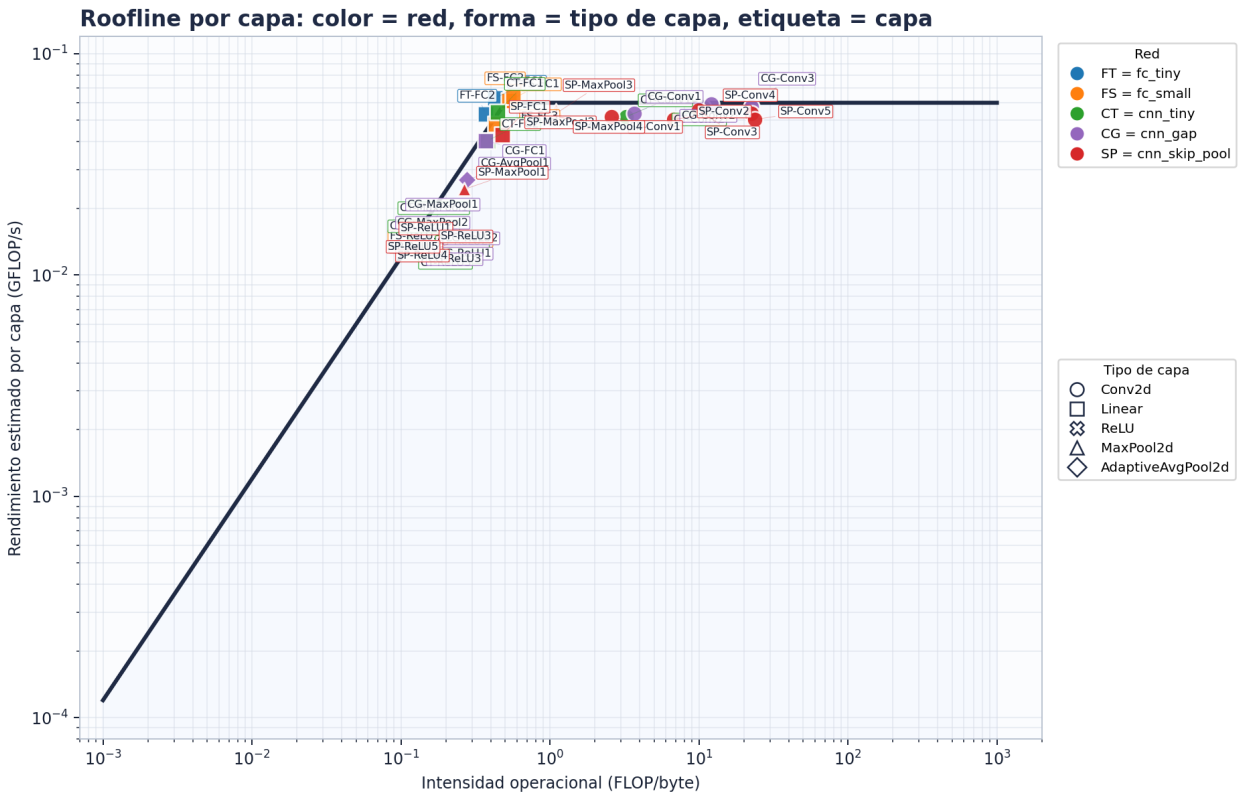

Mapa de etiquetas del Roofline

FT = fc_tiny

Etiqueta	Capa / tipo	Salida
FT-FC1	net.1 (FC)	1x128
FT-ReLU1	net.2 (ReLU)	1x128
FT-FC2	net.3 (FC)	1x4

FS = fc_small

Etiqueta	Capa / tipo	Salida
FS-FC1	net.1 (FC)	1x256
FS-ReLU1	net.2 (ReLU)	1x256
FS-FC2	net.4 (FC)	1x64
FS-ReLU2	net.5 (ReLU)	1x64
FS-FC3	net.6 (FC)	1x4

CT = cnn_tiny

Etiqueta	Capa / tipo	Salida
CT-Conv1	features.0 (Conv)	1x4x96x96
CT-ReLU1	features.1 (ReLU)	1x4x96x96
CT-MaxPool1	features.2 (MaxPool)	1x4x48x48
CT-Conv2	features.3 (Conv)	1x8x48x48
CT-ReLU2	features.4 (ReLU)	1x8x48x48
CT-MaxPool2	features.5 (MaxPool)	1x8x24x24
CT-FC1	classifier.1 (FC)	1x64
CT-ReLU3	classifier.2 (ReLU)	1x64
CT-FC2	classifier.3 (FC)	1x4

CG = cnn_gap

Etiqueta	Capa / tipo	Salida
CG-Conv1	features.0 (Conv)	1x4x96x96
CG-ReLU1	features.1 (ReLU)	1x4x96x96
CG-MaxPool 1	features.2 (MaxPool)	1x4x48x48
CG-Conv2	features.3 (Conv)	1x8x48x48
CG-ReLU2	features.4 (ReLU)	1x8x48x48
CG-MaxPool 2	features.5 (MaxPool)	1x8x24x24
CG-Conv3	features.6 (Conv)	1x16x24x24
CG-ReLU3	features.7 (ReLU)	1x16x24x24
CG-AvgPool1	features.8 (AvgPool)	1x16x1x1
CG-FC1	classifier (FC)	1x4

SP = cnn_skip_pool

Etiqueta	Capa / tipo	Salida
SP-MaxPool1	skip_pool (MaxPool)	1x1x12x12
SP-Conv1	conv.0 (Conv)	1x4x48x48
SP-ReLU1	conv.1 (ReLU)	1x4x48x48
SP-MaxPool2	conv.2 (MaxPool)	1x4x48x48
SP-Conv2	conv.3 (Conv)	1x8x24x24
SP-ReLU2	conv.4 (ReLU)	1x8x24x24
SP-MaxPool3	conv.5 (MaxPool)	1x8x24x24
SP-Conv3	conv.6 (Conv)	1x12x12x12
SP-ReLU3	conv.7 (ReLU)	1x12x12x12
SP-MaxPool4	conv.8 (MaxPool)	1x12x12x12
SP-Conv4	conv.9 (Conv)	1x12x12x12
SP-ReLU4	conv.10 (ReLU)	1x12x12x12
SP-Conv5	conv.11 (Conv)	1x16x12x12
SP-ReLU5	conv.12 (ReLU)	1x16x12x12
SP-FC1	classifier.1 (FC)	1x4

Analisis y decision

Modelo	Veredicto	Analisis
fc_tiny / fc_small	No recomendadas	Accuracy alrededor de 60%, pero pesos de 4.50 MB y 9.06 MB en float32; exceden la SRAM interna.
cnn_tiny	Buen accuracy, mala memoria	Mejor test acc (67.27%), pero 1.13 MB de parametros. Requiere PSRAM o int8 para ser realista.
cnn_gap	Muy pequena, baja precision	Solo 6.1 KB de pesos, pero test acc de 50.00%.
cnn_skip_pool	Elegida	66.82% test acc, 73.35% val acc, 54.9 KB de pesos, 0.82 MMACs, 27.3 ms y 36.7 FPS estimados.

Decision final: usar cnn_skip_pool. Mantiene accuracy competitivo frente a cnn_tiny, pero con una fraccion del tamano y menor costo computacional. Para la implementacion final en ESP32-S3 se recomienda cuantizacion int8 con

ESP-NN/TFLite Micro.